

RL pentru conducere autonomă într-un mediu personalizat “Highway”

Mediu personalizat “Highway”

Echipa Juno: Corobana Ingrid, Moise Irina, Prizlopan Iustin, Sescu Matei

Universitatea din București

Ianuarie 2026


Problema și obiectivul

Scop: Antrenarea unui agent care să conducă un vehicul (mașina galbenă) într-un mediu de trafic cu mai multe benzi.

Cerințe:

- Să evite coliziunile cu mașinile albastre
- Să rămână pe carosabil
- Să mențină o viteză rezonabilă

Abordare: Reinforcement Learning — agentul învață din recompense, fără supervizare explicită.



Schema agent-mediu

Stare, Acțiune, Recompensă

Stare (observație)

Vector continuu de 25 dimensiuni: poziția, viteza și orientarea vehiculului ego + informații despre vehiculele din jur.

Acțiuni (discrete)

- 0 Idle (nu face nimic)
- 1 Accelerează
- 2 Frânează
- 3 Virează stânga
- 4 Virează dreapta

Recompensă

-1 coliziune/ieșire drum +1 viteză (aliniată bandă) / centru bandă


Designul mediului (environment)

Drum personalizat:

- Segment drept de intrare
- Zonă de îmbinare (merge)
- Viraj circular
- Porțiuni drepte
- Ieșire verticală

Vehicle:

- **Ego** = mașina controlată
- **Trafic** = mașini IDM (model de conducere realist)



Schemă simplificată a drumului

Algoritmi implementați

Tabular Q-Learning

- Stare discretizată (6 dim)
- Tabel Q de 1944 stări
- Update Bellman clasic
- ϵ -greedy

DQN


- Stare continuă (25 dim)
- Rețea: $256 \rightarrow 128 \rightarrow 5$
- Experience Replay
- Target Network
- Double DQN

REINFORCE + Baseline

- Policy network
- Value network
- Monte Carlo returns
- Advantage
 $A_t = G_t - V(s_t)$


Toți agenții folosesc aceleași 5 acțiuni discrete și același mediu.

Curbe de antrenare




DQN converge cel mai rapid și atinge recompense mai mari. REINFORCE este mai instabil. Tabular învață mai lent.


Vizualizarea comportamentului



DQN




REINFORCE



Tabular

- Culorile indică acțiunile alese în fiecare poziție
- DQN: traiectorie fluidă, schimbări de bandă planificate
- Tabular: decizii mai „rigide” din cauza discretizării

Evaluare și comparație



Ce arată graficul:

- Înălțimea barei = recompensa medie pe 20 episoade de test
- Linia de eroare = deviația standard
- Cu cât bara e mai înaltă, cu atât agentul e mai bun

Concluzie:

În general DQN > REINFORCE > Tabular, dar variază în funcție de antrenare.

Hiperparametri cheie

Parametru	DQN	REINFORCE
Learning rate	5×10^{-4}	10^{-3}
Discount γ	0.99	0.99
Epsilon decay	0.99	—
Buffer size	50,000	—
Batch size	64	—
Hidden layers	[256, 128]	[64]
Episoade	500	1000

Ce a ajutat: reward shaping, Double DQN, value baseline pentru REINFORCE.

Ce a fost dificil: stabilitatea policy gradient, designul recompensei.

Ce a funcționat bine:

- DQN + stare kinematics (25 dim)
- Mediu personalizat highway_env
- Experience replay + target net
- Value baseline pentru REINFORCE

Direcții viitoare:

- PPO, A2C (algoritmi mai stabili)
- Acțiuni continue native
- Scenarii mai complexe (intersecții)
- Robustețe la zgomot pe observații

Proiectul demonstrează aplicarea practică a conceptelor de RL (Q-Learning, DQN, Policy Gradient) într-un scenariu de conducere autonomă.

Întrebări?

Demo disponibil cu python `demo_agent.py`

Cod sursă: https://github.com/dirgnic/RL_project